Sveučilište u Zagrebu Fakultet elektrotehnike i računarstva

Međuispit iz predmeta **TEORIJA INFORMACIJE**, 27. studenog 2020.

Pravilo bodovanja zadataka

Svaki točno odgovoreni zadatak donosi 5 bodova, netočno odgovoreni 2 negativna boda, a neodgovoreni 0 bodova.

Zadatak 1. Promatrajte izvor na čijem se izlazu pojavljuju dva simbola, i to: točka (•) i crtica (–). Trajanje točke iznosi 0,2 s, trajanje crtice je tri puta dulje, a trajanje stanke između simbola iznosi 0,2 s. Vjerojatnost pojavljivanja točke je dva puta veća od vjerojatnosti pojavljivanja crtice. Izračunajte prosječnu brzinu generiranja informacije izvora u jedinici bit/s.

- a) 0.4897 bit/s:
- b) 2,7552 bit/s;
- c) 0,9183 bit/s;
- d) 1,7219 bit/s;
- e) Ništa od navedenog.

Postupa rješavanja:

Dakle, trajanje simbola točka $t_1 = t(\bullet) = 0.2$ s, trajanje simbola crtica $t_2 = t(-) = 0.6$ s, a trajanje stanke $t_8 = 0.2$ s. Neka je vjerojatnost pojavljivanja točke $P(\bullet) = p_1$, a vjerojatnost pojavljivanja crtice $P(-) = p_2$. S obzirom da je zadano $p_1 = 2p_2$, a mora vrijediti i jednakost $p_1 + p_2 = 1$, slijedi da je $p_2 = 1/3$, a $p_1 = 2/3$. Prosječna količina informacije po svakom simbolu određuje se proračunom entropije zadanog izvora:

$$H(X) = -\sum_{i=1}^{2} p_i \log_2 p_i = 0.9183 \frac{\text{bit}}{\text{simbol}}.$$

S obzirom da se iza svakog simbola generira i stanka, za prosječno trajanje generiranog simbola vrijedi:

$$T = p_1(t_1 + t_s) + p_2(t_2 + t_s) = p_1t_1 + p_2t_2 + t_s = 0,5333 \frac{s}{\text{simbol}}$$

Konačno, prosječna brzina generiranja informacije u jedinici vremena iznosi:

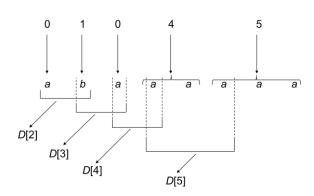
$$R = \frac{H(X)}{T} = \frac{0.9183}{0.5333} = 1,7219 \frac{\text{bit}}{\text{s}}$$
.

Zadatak 2. Temeljem polaznog rječnika D[0] = a i D[1] = b dekodirajte primljenu poruku 0 1 0 4 5 koristeći algoritam LZW.

- a) abaaaaa (7 znakova);
- b) abaaaaaaa (9 znakova);
- c) abaaaaaa (8 znakova);

- d) abaaaa (6 znakova);
- e) Ništa od navedenog.

Postupak rješavanja:



Prošireni rječnik: D[2] = ab, D[3] = ba, D[4] = aa, D[5] = aaa. Dekodirana poruka: abaaaaaa.

Zadatak 3. Komunikacijskim kanalom prenose se četiri poruke generirane iz skupa X koji sadrži četiri simbola, $X = \{x_1, ..., x_4\}$. Omjer vjerojatnosti njihovog pojavljivanja na izvoru, tj. na ulazu kanala iznosi: $P(x_1) : P(x_2) : P(x_3) : P(x_4) = 1 : 2 : 2 : 5$. Matrica kanala zadana je kao:

$$\begin{bmatrix} 0.1 & 0.2 & 0.2 & 0.5 \\ 0.1 & 0.2 & 0.5 & 0.2 \\ 0.1 & 0.5 & 0.2 & 0.2 \\ 0.5 & 0.1 & 0.2 & 0.2 \end{bmatrix}.$$

Odredite transinformaciju u zadanom kanalu.

- a) 0.226 bit/simbol; b) 1,761 bit/simbol; c) 1,535 bit/simbol; d) 0,538 bit/simbol;
- e) Ništa od navedenog.

Postupa rješavanja:

S obzirom na zadane omjere vjerojatnosti i na činjenicu da mora vrijediti da je zbroj vjerojatnosti svih simbola izvora jednak 1, slijedi

$$p(x_1) = 0.1$$

 $p(x_2) = p(x_3) = 0.2$
 $p(x_4) = 0.5$

Nadalje, kako bio odredili vjerojatnosti simbola na izlazu kanala, $P(y_j)$, j = 1, ..., 4, trebamo odrediti matricu združenih vjerojatnosti

$$[P(x_i, y_j)] = [P(x_i) \cdot P(y_j \mid x_i)] = \begin{bmatrix} 0.01 & 0.02 & 0.02 & 0.05 \\ 0.02 & 0.04 & 0.1 & 0.04 \\ 0.02 & 0.1 & 0.04 & 0.04 \\ 0.25 & 0.05 & 0.1 & 0.1 \end{bmatrix}$$

Dakle, $[P(y_j)] = [0,3 \quad 0,21 \quad 0,26 \quad 0,23]$. Sada je moguće odrediti entropije H(X), H(Y) i H(X, Y), te preko njih u konačnici transinformaciju I(X; Y) = H(X) + H(Y) - H(X, Y):

$$H(X) = -\sum_{i=1}^{4} P(x_i) \log_2 P(x_i) = 1,761 \frac{\text{bit}}{\text{simbol}},$$

$$H(Y) = -\sum_{j=1}^{4} P(y_j) \log_2 P(y_j) = 1,9869 \frac{\text{bit}}{\text{simbol}},$$

$$H(X,Y) = -\sum_{i=1}^{4} \sum_{j=1}^{4} P(x_i, y_j) \log_2 P(x_i, y_j) = 3,5219 \frac{\text{bit}}{\text{simbol}}.$$

Konačno, I(X; Y) = 0.226 bit/simbol.

Zadatak 4. Poruka "aaaaabaaaaa*" (navodnici nisu dio poruke, * je oznaka kraja poruke) kodira se algoritmom LZ77 tako da maksimalna duljina posmičnog prozora iznosi 1 simbol, a prozora za kodiranje 5 simbola. Koliko uređenih trojki (*pomak, duljina, sljedeći simbol*) generira navedeni algoritam kako bi kodirao poruku?

a) Pet; b) Šest; c) Tri; d) Četiri; e) Ništa od navedenog.

Postupak rješavanja:

U postupku kodiranja dobiju se četiri trojke: (0,0,a), (1,4,b), (0,0,a) i (1,4,*).

Zadatak 5. Diskretni komunikacijski kanal opisan je matricom:

$$[P(y_j|x_i)] = \begin{bmatrix} 0.8 & 0.2 & 0 & 0\\ 0.2 & 0.8 & 0 & 0\\ 0 & 0 & 0.8 & 0.2\\ 0 & 0 & 0.2 & 0.8 \end{bmatrix}.$$

Odredite kapacitet takvog kanala.

a) 0.226 bit/s; b) 1,2781 bit/simbol; c) 1,535 bit/s; d) 0,538 bit/s; e) Ništa od navedenog.

Postupa rješavanja:

Očito se radi o slabo simetričnom kanalu. Svi su reci matrice kanala permutacije jedni drugih, a zbroj svih elemenata po svakom stupcu je jednak (iznosi 1). Dakle, kapacitet takvog kanala možemo odrediti koristeći izraz:

$$C = \log_2 \left[\operatorname{card}(Y) \right] - H(Y|x)$$

Broj simbola na izlazu kanala iznosi card(Y) = 4, a matricu H(Y|x) računamo za jedan redak matrice kanala:

$$H(Y|x) = \sum_{j=1}^{4} P(y_j|x_i) \log\left(\frac{1}{P(y_j|x_i)}\right) = 0,2\log_2 5 + 0,8\log_2 1,25 = 0,7219 \frac{\text{bit}}{\text{simbol}}$$

Konačno, C = 2 - 0.7219 = 1.2781 bit/simbol.

Zadatak 6. Zadan je informacijski izvor s memorijom modeliran markovljevim lancem s dva stanja. Taj je lanac opisan matricom prijelaznih vjerojatnosti:

$$\begin{bmatrix} 5/8 & 3/8 \\ 3/4 & 1/4 \end{bmatrix}.$$

Odredite entropiju izvora.

- a) 0,2704 bit/simbol; b) 0,9067 bit/simbol; c) 0,8115 bit/simbol; d) 0,6363 bit/simbol;
- e) Ništa od navedenog.

Postupak rješavanja:

Stacionarne vjerojatnosti lanca $\pi = [\pi_0, \pi_1]$ moguće je odrediti temeljem jednakosti $\Pi^T \pi = \pi$:

$$\begin{bmatrix} 5/8 & 3/8 \\ 3/4 & 1/4 \end{bmatrix}^{\mathrm{T}} \cdot \begin{bmatrix} \pi_0 \\ \pi_1 \end{bmatrix} = \begin{bmatrix} \pi_0 \\ \pi_1 \end{bmatrix}.$$

Pomoćni izraz je $\pi_0 + \pi_1 = 1$. Dakle, $\pi_0 = 2/3$, $\pi_1 = 1/3$. Sada je moguće odrediti entropiju izvora:

$$H = -\sum_{i=0}^{1} \pi_{i} \sum_{j=0}^{1} p_{ij} \log \left(p_{ij} \right) = -\frac{2}{3} \left(\frac{5}{8} \log_{2} \frac{5}{8} + \frac{3}{8} \log_{2} \frac{3}{8} \right) - \frac{1}{3} \left(\frac{3}{4} \log_{2} \frac{3}{4} + \frac{1}{4} \log_{2} \frac{1}{4} \right) = 0,9067 \frac{\text{bit}}{\text{simbol}}$$

Zadatak 7. Zadan je skup X koji sadrži dva simbola, x_1 i x_2 . Simbol x_1 ima stvarnu (izmjerenu) vjerojatnost nastupa $P(x_1) = 0.6$. Promatrač eksperimenta greškom zamijeni vjerojatnosti nastupa simbola x_i , i = 1, 2, jednu s drugom. Odredite relativnu entropiju stvarne prema pogrešnoj razdiobi vjerojatnosti simbola.

- a) 0 bit/simbol; b) 0,351 bit/simbol; c) -0,234 bit/simbol; d) 0,117 bit/simbol;
- e) Ništa od navedenog.

Postupak rješavanja:

Relativna entropija jedne prema drugoj razdiobi vjerojatnosti nastupa simbola, npr. $P(x_i)$ prema $Q(x_i)$, izračunava se izrazom:

$$D(P||Q) = \sum_{i=1}^{n} P(x_i) \log_2 \frac{P(x_i)}{Q(x_i)}$$

Dakle, u ovom konkretnom slučaju opisanom u tekstu zadatka vrijedi:

$$D(P||Q) = \sum_{i=1}^{2} P(x_i) \log_2 \frac{P(x_i)}{Q(x_i)} = 0, 6 \cdot \log_2 \frac{0.6}{0.4} + 0, 4 \cdot \log_2 \frac{0.4}{0.6} = 0,117 \frac{\text{bit}}{\text{simbol}}$$

Zadatak 8. Neki skup simbola X sadrži pet simbola x_i , i = 1, ..., 5. Njihove su vjerojatnosti: $P(x_1) = 3/7$, $P(x_2) = P(x_3) = P(x_4) = P(x_5) = 1/7$. Zadani skup simbola potrebno je kodirati tehnikom Shannon-Fano te odrediti minimalnu srednju duljinu kodne riječi koju tako kreirani kôd može imati nad zadanim skupom simbola.

- a) 2,143 bit/simbol; b) 2,286 bit/simbol; c) 1,571 bit/simbol; d) 1,857 bit/simbol;
- e) Ništa od navedenog.

Postupak rješavanja:

Tehnika kodiranja Shannon-Fano ne daje uvijek optimalan kôd. U promatranom slučaju zadani skup simbola s pripadajućim vjerojatnostima moguće je kodirati na dva bitno različita načina:

Odgovarajuće srednje duljine kodnih riječi su L_a i L_b :

$$L_{a} = \sum_{i=1}^{5} l_{i} \cdot P(x_{i}) = 1 \cdot \frac{3}{7} + 4 \cdot 3 \cdot \frac{1}{7} = \frac{15}{7} = 2,143 \frac{\text{bit}}{\text{simbol}}$$

$$L_{b} = \sum_{i=1}^{5} l_{i} \cdot P(x_{i}) = 2 \cdot \frac{3}{7} + 2 \cdot 2 \cdot \frac{1}{7} + 2 \cdot 3 \cdot \frac{1}{7} = \frac{16}{7} = 2,286 \frac{\text{bit}}{\text{simbol}}$$

Dakle, minimalna srednja duljina kodne riječi nad promatranim skupom simbola iznosi 2,143 bit/simbol.

Zadatak 9. Promatrajte skup X koji sadrži 9 simbola, svaki s vjerojatnošću $p_i \in (0, 1)$, i = 1, ..., 9, zbroj svih vjerojatnosti p_i iznosi 1. Sada fiksirajmo jednu vjerojatnost, neka je $p_1 = 0.25$. Odredite

maksimum entropije $H(0,25, p_2, ..., p_9)$. Napomena: općenito, $H(p_1, ..., p_n)$ je način zapisa entropije diskretne slučajne varijable X s n simbola čije su vjerojatnosti p_i , i = 1, ..., n.

a) 3,1699 bit/simbol; b) 3,0613 bit/simbol; c) 3 bit/simbol; d) 0,8113 bit/simbol;

e) Ništa od navedenog.

Postupak rješavanja:

Općenito, ako vrijedi $1 \le r \le n$, $q_1 = p_1 + ... + p_r$ i $q_2 = p_{r+1} + ... + p_n$ tada je

$$H(p_1,...,p_n)=H(q_1,q_2)+q_1H\left(\frac{p_1}{q_1},...,\frac{p_r}{q_1}\right)+q_2H\left(\frac{p_{r+1}}{q_2},...,\frac{p_n}{q_2}\right)$$

U našem slučaju n = 9, r = 1, $q_1 = 0.25$, a $q_2 = 0.75$. Sukladno tome vrijedi:

$$\begin{split} &H\left(0,25,p_{2},...,p_{9}\right)=H\left(q_{1},q_{2}\right)+q_{1}\cdot H\left(\frac{p_{1}}{q_{1}}\right)+q_{2}\cdot H\left(\frac{p_{2}}{q_{2}},...,\frac{p_{9}}{q_{2}}\right)=\\ &=H\left(\frac{1}{4},\frac{3}{4}\right)+\frac{1}{4}\cdot H\left(1\right)+\frac{3}{4}\cdot H\left(\frac{p_{2}}{q_{2}},...,\frac{p_{9}}{q_{2}}\right) \end{split}$$

H(1) = 0, a očito je da će entropija $H(0,25, p_2, ..., p_9)$ imati maksimalni iznos kad je i entropija $H(p_2/q_2, ..., p_n/q_2)$ maksimalna. S obzirom da vrijedi:

$$\sum_{i=2}^{9} p_i = q_2 \to \sum_{i=2}^{9} \frac{p_i}{q_2} = 1,$$

možemo primijeniti opće poznato svojstvo da je entropija $H(\pi_1, ..., \pi_m)$, $\sum_{i=1}^m \pi_i = 1$, maksimalna kad vrijedi $\pi_i = 1/m$, za svaki i = 1, ..., m. Dakle, u našem specifičnom slučaju, kako bi ukupna entropija poprimila maksimalnu vrijednost, mora vrijediti:

$$\frac{p_2}{q_2} = \dots = \frac{p_9}{q_2} = \frac{1}{8}$$

Sukladno tome vrijedi:

$$\max_{\{p_i|i=2,\ldots,9\}} H(0,25,p_2,\ldots,p_9) = H\left(\frac{1}{4},\frac{3}{4}\right) + \frac{1}{4} \cdot H(1) + \frac{3}{4} \cdot H\left(\frac{1}{8},\ldots,\frac{1}{8}\right).$$

Sada možemo odrediti maksimalnu vrijednost entropije kao:

$$\max_{\{p_i|i=2,...,9\}} H(0,25,p_2,...,p_9) = -\frac{1}{4}\log_2\frac{1}{4} - \frac{3}{4}\log_2\frac{3}{4} + \frac{3}{4}\cdot\log_28 =$$

$$= \frac{1}{2} + \frac{3}{2} - \frac{3}{4}\log_23 + \frac{9}{4} = \frac{17}{4} - \frac{3}{4}\log_23 = 3,0613 \frac{\text{bit}}{\text{simbol}}$$

Zadatak 10. Promatrani skup X sadrži N simbola x_i . Za vjerojatnosti tih simbola vrijedi:

$$1 > P(x_1) > P(x_2) > ... > P(x_{N-1}) \ge P(x_N) > 0, \sum_{i=1}^{N} P(x_i) = 1.$$

Simbole x_i kodiramo Huffmanovim kodom. Svaki simbol pri tome kodiramo s l_i bita. Odredite zbroj $\sum_{i=1}^{N} l_i$, ako je L = H(X).

a) $N \cdot (N + 1)/2$ [bit];

b) N^2 [bit]; c) $(N-1)\cdot(N+2)/2$ [bit]; d) $N\cdot(N-1)/2$ [bit];

e) Ništa od navedenog.

Postupak rješavanja:

Ako vrijedi L = H(X), tada mora vrijediti:

$$\sum_{i=1}^{N} l_{i} P(x_{i}) = -\sum_{i=1}^{N} P(x_{i}) \log_{2} P(x_{i})$$

iz čega slijedi da mora vrijediti: $l_i = -\log_2 P(x_i)$. S obzirom da su duljine kodnih riječi cjelobrojne, slijedi da vjerojatnosti $P(x_i)$ moraju biti oblika 2^{-k} , $k \in \mathbb{N}$. Nadalje, s obzirom da općenito vrijedi

$$\sum_{i=1}^{M} 2^{-i} = 1 - 2^{-M}$$

te uzevši u obzir početni uvjet o međusobnim odnosima između vjerojatnosti $P(x_i)$, slijedi da vjerojatnosti simbola x_i moraju zadovoljavati sljedeće:

$$P(x_i) = \begin{cases} 2^{-i}, & i = 1, ..., N-1 \\ 2^{-N+1}, & i = N \end{cases}.$$

Za takav skup vjerojatnosti $P(x_i)$ zadovoljen je i uvjet da njihov zbroj mora iznositi 1. Sukladno tome, vrijedi:

$$l_i = \begin{cases} i, & i = 1, \dots, N - 1 \\ N - 1, & i = N \end{cases}$$

i u konačnici

$$\sum_{i=1}^{N} l_i = \sum_{i=1}^{N-1} i + (N-1) = \frac{(N-1) \cdot N}{2} + (N-1) = \frac{(N-1) \cdot (N+2)}{2}$$
[bit].